

Predviđanje afiniteta vezivanja inhibitora humanog tripsina primenom višestruke regresione analize i transfer learning pristupa

1. Opis problema

Humani tripsin je enzim, koji ima ključnu ulogu u varenju proteina. [1, 2] Inhibitori tripsina, molekuli koji smanjuju aktivnost enzima ili je potpuno sprečavaju, imaju veliku primenu u lečenju oboljenja povezanih sa pankreasom. Predviđanje afiniteta vezivanja liganada (malih molekula) za proteinske mete, kao što je enzim tripsin, predstavlja ključan problem u procesu dizajna lekova.

Ovaj enzim raspolaže srednjim brojem eksperimentalnih merenja afiniteta vezivanja (oko 1500 izmerenih vrednosti). S druge strane, kravlji tripsin, koji je strukturno visoko analogan humanom tripsinu (oko 80% sekvence je identično), poseduje oko 1000 eksperimentalnih merenja afiniteta vezivanja inhibitora. Iako je dostupna velika količina eksperimentalnih merenja za humani tripsin, transfer learning pristup će biti primenjen kako bi se istražili odgovori na pitanje: Da li model koji je treniran na podacima za kravlji tripsin može poboljšati generalizaciju modela na humani tripsin i dati preciziju predikciju u poređenju sa modelom treniranim isključivo na humanim podacima? Dodatna pitanja na koje ovaj projekat pokušava da odgovori su:

1. Koji model će davati najniži RMSE za skup podataka humanog tripsina?
2. Koliko je korelacija između predviđanja modela, rezultata molekulskog dokinga i eksperimentalnih vrednosti za derivate cimetne kiseline dobijenih u IS Petnica[5]?
3. Identifikacija ključnih molekulskih karakteristika i funkcionalnih grupa koje najviše utiču na afinitet vezivanja putem SHAP interpretabilnosti modela.

Projekat će se fokusirati na razvoj robusnih regresionih modela, koji će moći da predvide afinitet vezivanja inhibitora za potpuno nove inhibitore humanog tripsina, koristeći cross-species transfer learning pristup. Pored predikcije afiniteta vezivanja, projekat će koristiti SHAP interpretabilnost da identifikuje ključne molekularne karakteristike koje određuju afinitet vezivanja.

2. Skup podataka

Podaci, na kojima će biti primenjene navedene metode, biće podeljeni u tri grupe:

1. **Grupa za treniranje modela** – Eksperimentalne vrednosti inhibitorske konstante(K_i) za humani i kravlji tripsin preuzete su iz baze ChEMBL (humani: <https://www.ebi.ac.uk/chembl/explore/target/CHEMBL209#ActivityCharts>, kravlji: <https://www.ebi.ac.uk/chembl/explore/target/CHEMBL3769>). Biće preuzeto oko 1500 merenja za humani i oko 1000 za kravlji tripsin.

Ciljnu promenljivu predstavlja eksperimentalno izmerena vrednost inhibitorske konstante(K_i), koja će biti konvertovana u pK_i pomoću formule $pK_i = -\log_{10}(K_i)$. pK_i predstavlja uobičajenu linearnu skalu za izražavanje jačine vezivanja.

Za svaki molekul, koji je određen SMILES stringom(hemijska reprezentacija), biće izračunato preko 2000 numeričkih deskriptora, koji opisuju njegova fizičko-hemijska svojstva. Neki od njih su: 2D deskriptori(molekulska masa, lipofilnost, broj donora ili akceptora vodonika, topološki polarna površina itd) i Morganovi fingerprintovi(vektor dužine 2048 bita, u kom svaki bit kodira prisustvo specifičnih podstruktura i funkcionalnih grupa u molekulu).

2. **Sintetički podaci (*In silico*)** – Za podskup od oko 70 molekula iz test skupa, biće urađen molekularni doking koristeći program AutoDock Vina, kako bi se dobile računarski predviđene vrednosti afiniteta vezivanja.
3. **Dva estra cimetne kiseline**, sintetisana od strane autorke [5] predloga projekta u IS Petnica, čije delovanje na enzim je već eksperimentalno provereno u laboratoriju IS Petnica, zbog čega će biti korišćeni za komparativnu analizu rezultata programa AutoDock Vina i rezultata dobijenih od strane modela

3. Metodologija

1. Prikupljanje i obrada podataka

Skup podataka biće preuzet iz ChEMBL baze podataka. Podaci koji predstavljaju duplikate ili sadrže nevalidne SMILES zapise biće uklonjeni. Za svaki validan molekul, pomoću RDKit biblioteke, biće generisani 2D deskriptori i Morganovi fingerprintovi, formirajući početnu matricu formata $N \times 2248$. Biće primenjen niz tehnika za smanjenje dimenzionalnosti i redukciju šuma, uključujući uklanjanje karakteristika sa niskom varijansom, uklanjanje visoko korelisanih parova, selekcija 200 najboljih karakteristika (zasnovanih na F-testu) i PCA (Principal Component Analysis), koja će svesti dimenzionalnost na 100 glavnih komponenti.

2. Implementacija modela

Biće implementirana i upoređena 3 različita scenarija treniranja za 6 predviđenih regresionih modela: Višestruka linearna regresija, Ridge regresija, Lasso regresija, Elastic net regresija, Random forest regressor i Gradient boosting regressor.

Biće upoređene preformanse 3 scenarija: treniranje modela isključivo na podacima za humani tripsin, transfer learning sa kravljeg tripsina i kombinacija oba skupa podataka, kako bi se utvrdilo u kojim scenarijima model donosi najbolje rezultate.[6,7]

3. Interpretabilnost modela i identifikacija ključnih karakteristika

SHAP analiza biće primenjena na najbolji regresioni model. Pomoću nje, biće izvršena identifikacija top 20 najvažnijih molekularskih karakteristika(specifični deskriptori ili Morganovi fingerprintovi) koje najviše utiču na predviđanje pKi. Na kraju, biće izvršena vizuelizacija doprinosa karakteristika.

4. Poređenje rezultata

Prvo će za određeni podskup podataka biti odrađen molekularni doking koristeći program AutoDock Vina (*in silico* analiza). Potom će biti izvršeno poređenje rezultata predikcije afiniteta vezivanja inhibitora dobijenih od modela i rezultata dobijenih *in silico* analizom test grupe podataka, nakon čega će rezultati biti i vizuelno predstavljeni. Na kraju, biće urađena i komparacija predikcija modela i *in silico* metode za dva derivata cimetne

kiseline u odnosu na eksperimentalne rezultate dobijene u IS Petnica. Poređenje sa rezultatima dobijenih molekulskim dokingom služi kako bi se odredilo koliko je najbolji model dobar u odnosu na doking, koji predstavlja jednu od trenutno najznačajnijih i najzastupljenijih računarskih metoda u kompjuterskoj hemiji.

5. Razvoj sistema za računanje kompatibilnosti

Biće izvršena analiza 3D strukture humanog tripsina i definisani optimalni opsezi za ključna svojstva (molekulska masa, naelektrisanje, donori vodonika, rotacione veze i sl). Biće izvršena implementacija funkcionalnosti generisanja malog izveštaja, na osnovu opsega ključnih svojstava (nešto nalik rezultatima krvne slike u kojima je navedeno šta je iznad, a šta ispod opsega i za koliko).

6. GUI okruženje

GUI okruženje će biti implementirano na način da korisniku nudi 2 opcije – predikciju afiniteta vezivanja inhibitora ili analizu kompatibilnosti. Takođe, biće omogućen unos SMILES stringa, kao i automatski prikaz 2D strukture koji će korisniku olakšati vizualizaciju, a ujedno i proveru unosa. Biće omogućen izbor modela po kom će biti rađena predikcija, kao i prikaz rezultata predikcije u formatu izveštaja koji uključuje predviđenu vrednost afiniteta vezivanja, RMSE i R^2 za odabrani model i listu najboljih inhibitora iz baze podataka i poređenje sličnosti korisnikovog molekula u odnosu na njih. Korisniku će biti dostupna i opcija da dobijeni izveštaj sačuva u poseban .txt fajl. Takođe, biće izvršena implementacija istorije poslednjih 5 korisnikovih upita i rezultata dobijenih sa njima.

4. Evaluacija

Humani dataset biće podeljen na tri dela:

- Trening skup(70%)
- Validacioni skup(15%)
- Test skup(15%)

Performanse modela biće evaluirane na izdvojenom test skupu(15% humanih podataka), koji model nikada nije video tokom treniranja. Za evaluaciju performansi modela biće korišćene tri metrike, jer svaka pruža drugačiji uvid:

- **RMSE** (Root Mean Square Error) predstavlja primarnu metriku. Ona meri prosečnu grešku predikcije u originalnim jedinicama (pKi). Veći značaj daje velikim greškama, što je korisno, jer su one najnepoželjnije u hemijskim ispitivanjima.
- **R^2** (koeficijent determinacije) u paru sa **R^2 adj** (prilagođeni koeficijent determinacije), jer pokazuju koliko varijacija u eksperimentalnim podacima model može da objasni. Prilagođeni koeficijent determinacije se koristi kao dodatna provera običnog R^2 .
- **MAE** (Mean Absolute Error), jer meri prosečnu grešku, ali na linearniji način u odnosu na RMSE. Dok RMSE kažnjava velike greške, MAE daje prosečno očekivano odstupanje. Korišćenjem obe metrike, MAE i RMSE, dobija se kompletna slika o distribuciji grešaka, npr. ako je

RMSE znatno veći od MAE, to bi ukazivalo na postojanje nekoliko velikih grešaka u predikcijama, poznatiji kao outliers.

Pored ovih metrika, biće izračunata i efikasnost transfera (odnos RMSE scenarija 1 i 2), kako bi se kvantitativno izmerilo da li je transfer learning doneo poboljšanja u predikciji.

4.1. Biblioteke

Biće korišćene sledeće biblioteke i programi:

- Scikit-learn za implementaciju svih 6 modela
- RDKit za generisanje molekularnih deskriptora, Morganovih fingerprintova i 2D vizualizaciju
- Pandas i numpy za manipulaciju podacima i operacije sa matricama
- Matplotlib i seaborn za vizualizacije i grafike
- Streamlit za GUI
- SciPy za statističke analize
- SHAP za interpretabilnost modela
- Programi AutoDock Vina, Chimera, ChemDraw i biblioteka meeko za molekulski doking (*in silico* analiza)

Ceo projekat će biti rađen u Python programskom jeziku.

5. Literatura

- [1] Elgendy, A., Abdelrasool, M. (2016). *A Literature Review on Trypsin Enzyme*, Katarski univerzitet
- [2] Huber, R. and Bode, W. (1978). *Structural basis of the activation and action of Trypsin*, Zbornik radova „Accounts of Chemical Research”, 11(3), str. 114-122.
- [3] Proteinska baza podataka (PDB : 1TRN) (januar 2026)
- [4] Gasteiger, J., Engel, T. (2003). *Chemoinformatics*, Wiley-VCH GmbH & Co. KGaA
- [5] Janković Aleksandra. (2023). *In silico i in vitro analiza uticaja estara p-hlorcimetne kiseline na aktivnost tripsina*, IS Petnica
- [6] Heck, G., Pinto, V. et al. (2017). *Supervised Machine Learning Methods Applied to Predict Ligand- Binding Affinity*, Current Medicinal Chemistry, 24(23), str. 2459-2470.
- [7] Mlinsek, G., Novic, M. et al. (2004). *Enzyme Binding Selectivity Prediction: α -Thrombin vs Trypsin Inhibition*, Zbornik radova „Journal of Chemical Information and Computer Sciences”, 44(5), str. 1872-1882.